

ZADANIA MODELOWANIA



Jaki jest typ zadania/zadań?
Dla jakich danych generowane są predykcje?
Jakie są możliwe wyniki predykcji?
Kiedy obserwowane są wyniki (etykiety)?

Typ zadania: Klasyfikacja / detekcja anomalii
Dla jakich danych: ID_oferty + Data
Możliwe wyniki: Cena zawyżona lub nie
Kiedy obserwacja: W przypadku tworzenia nowej oferty oraz po określonym czasie odświeżenia predykcji

DECYZJE



Jak predykcje przekształcane są w konkretne rekomendacje lub zmiany dla użytkownika końcowego?

Wykrycie zawyżonej ceny przez model przełoży się na rekomendację obniżenia ceny. W przypadku pozostawienia ceny bez zmian, klient będzie widział, że dana oferta jest zawyżona.

PROPOZYCJA WARTOŚCI



Kto jest ostatecznym beneficjentem i jakie konkretne problemy są rozwiązywane?
Jak system uczenia maszynowego zostanie zintegrowany z istniejącym rozwiązaniem?

Ostatecznym beneficjentem jest klient, poprzez wgląd do wyselekcjonowanej oferty pokoi. Nie musi przeglądać ofert z zawyżonymi cenami.

Dodatkowo podniesie się wartość portalu, a ceny lokali nie będą zaburzone przez outliery. Ponadto niedoświadczeni oferenci będą wiedzieć, czy ich cena nie jest zbyt zawyżona.

ZBIERANIE DANYCH



Jakie strategie stosowane są do aktualizacji danych po wdrożeniu?

Etykietowanie przez zespół obsługi klienta / moderatorów ofert na podstawie zgłoszeń od użytkowników oraz wyrwykowe etykietowanie losowych ofert, by pokryć przestrzeń wszystkich ofert.

ŹRÓDŁA DANYCH



Jakie źródła danych będą potrzebne do skonstruowania wstępnego zbioru danych uczących?
Jak zdefiniowane będą etykiety?

- **Szczegółowe dane o dostępnych lokalach:** Standard, lokalizacja, maksymalna liczba gości
- **Baza klientów i sesji:** Czy ktokolwiek kiedykolwiek wyświetlił lub zarezerwował ten lokal w takiej cenie?
- **Opinie o lokalach:** Oceny wystawione danej ofercie
- **Etykiety:** początkowo utworzone poprzez grupowanie podobnych ofert i oznaczanie cen odstających od reszty

Etykiety: Anomalia:
1 – Anomalia
0 – Niezawyżona cena

WPLYW PROJEKTU



Jakie są wartości kosztów/zysków dla (nie)poprawnych decyzji?
Jakie dane są używane do symulacji wpływu przed wdrożeniem?
Jakie są kryteria sukcesu?

TP (Zysk): Oczyszczenie wyników wyszukiwania.
TN: brak zmian
FP (Koszt): Propozycja zmiany wysokiej, ale poprawnej ceny, frustracja oferenta, mniej ofert widocznych dla klienta
FN (Koszt): Anomalia nie zostaje usunięta, brak poprawy.

GENEROWANIE PREDYKCJI



Czy predykcje generowane są wsadowo (batch) czy w czasie rzeczywistym?
Jak często?
Ile czasu jest dostępne na generowanie predykcji?

- W czasie rzeczywistym, podczas tworzenia/edycji oferty – czas max. 2s
- Wsadowo, raz na tydzień, dla wszystkich ofert – czas max. 6h

Integracja:

- Widoczna dla klienta: poprzez dołączenie do oferty widocznej łatki: cena zawyżona/niezawyżona
- Oferent: Podczas tworzenia/edycji oferty, przed zatwierdzeniem pojawi się sugestia odnośnie ceny

BUDOWANIE MODELI



Ile modeli jest potrzebnych na środowisku produkcyjnym?
Kiedy powinny być aktualizowane?
Ile czasu jest dostępne na to (włącznie z wyznaczaniem atrybutów i analizą)?

Modele: jeden główny model do detekcji anomalii
Aktualizacja, czas: Aktualizacja co kwartał/sezon, aby model "uczył się" trendów i naturalnych zmian na rynku turystycznym.

ATRYBUTY



Jakie reprezentacje encji są używane w czasie generowania predykcji?
Jakie agregacje lub transformacje są stosowane do surowych źródeł danych?

Z dat zostanie wyciągnięty rok; Tekst będzie zastąpiony numeryczną wartością po analizie cech lokalu; wartościowe kategoryczne: uproszczone kodowanie dyskretne mające biznesowy sens;

Agregacje:

- średnia opinia o lokalu w ostatnim roku i całej historii
- liczba wyświetleń i rezerwacji w różnych oknach czasowych
- różne dane o długościach rezerwacji (min, max, średnia, suma)
- czy lokal kiedykolwiek najęty
- średni czas od wynajęcia

Dane historyczne o ofertach, sesjach i opiniach z ostatnich lat. Kryterium biznesowe: Spadek po 2 tygodniach liczby ofert z zawyżonymi cenami o 30%, przy pozostawieniu co najmniej 90% niezawyżonych ofert. Kryterium analityczne: Swoistość $\geq 90\%$ i czułość $\geq 30\%$			 MONITOROWANIE Jakie metryki i KPI są używane do śledzenia wpływu systemu uczenia maszynowego po wdrożeniu, zarówno dla użytkowników końcowych, jak i dla biznesu? Jak często powinny być przeglądane? Metryki ML: Swoistość (minimalizacja błędnego flagowania poprawnych ofert – wysoki biznesowy koszt FP), precyzja wykrytych anomalii i czułość wykrywania faktycznych anomalii. Współczynnik akceptacji rekomendacji (Conversion Rate): Odsetek oferentów, którzy po otrzymaniu alertu o zawyżonej cenie faktycznie ją obniżyli. Wskaźnik irytacji (Alert Fatigue): Odsetek oferentów, którzy kliknęli "Ignoruj", "Nie pokazuj więcej" lub zamknęli powiadomienie bez podejmowania akcji. Powinny być przeglądane raz na tydzień, tuż przed aktualizacją predykcji.	do rozpoczęcia okresu rezerwacji Transformacje: • obliczenie wyniku premium dla udogodnień w lokalach • nowe kodowanie typów pokoi • czyszczenie niespójnych id między tabelami • imputacje brakujących danych • normalizacja danych
---	--	--	--	---



Dokument jest utworzony na podstawie: OWNML MACHINE LEARNING CANVAS v 1.2. Created by Louis Dorard, Ph.D. Licensed under a [Creative Commons Attribution-ShareAlike 4.0 International License](https://creativecommons.org/licenses/by-sa/4.0/).

OWNML.CO